

# Probabilidad y Estadística

Santiago Sierra

# Índice general

## Chapter 1

		Page 2
1.1	Cálculo de probabilidades	2
1.2	Modelo de equiprobabilidad	4
1.3	Probabilidad Condicional	4

## Chapter 2

	<b>Variables aleatorias</b>	Page 6
2.1	Variables aleatorias discretas con nombre	11

# Capítulo 1

## 1.1. Cálculo de probabilidades

### Definición 1.1.1

La probabilidad de un evento  $A$ , es un número real en el intervalo  $[0, 1]$  que denotaremos por  $P(A)$ .

### Definición 1.1.2: Espacio muestral

Es el conjunto  $\Omega$  de todos los resultados posibles de un evento. Los elementos del espacio muestral se denotan usualmente por la letra  $\omega$  y se llaman eventos simples o elementales.

### Definición 1.1.3: Cardinal

Es el número de elementos de un evento, lo escribimos como  $|A|$ .

### Definición 1.1.4: Probabilidad Clásica

Sea  $A$  un subconjunto de un espacio muestral  $\Omega$  de cardinalidad finita. Definimos la probabilidad de un evento  $A$  como:

$$P(A) = \frac{|A|}{|\Omega|}$$

### Definición 1.1.5: $\sigma$ -álgebra

$$\mathcal{M} \text{ es } \sigma\text{-álgebra} \Leftrightarrow \begin{cases} \Omega \in \mathcal{M} \\ \text{Si } A \in \mathcal{M} \rightarrow A^c \in \mathcal{M} \\ \text{Si } A_1, A_2, \dots, A_n \in \mathcal{M} \rightarrow \bigcup_{m=1}^{\infty} A_m \in \mathcal{M} \end{cases}$$

### Definición 1.1.6: Espacio de probabilidad

Diremos que  $(\Omega, \mathcal{M}, P)$  con  $\Omega \neq \emptyset$  es un espacio de probabilidad si y solo si  $\mathcal{M}$  es una  $\sigma$ -álgebra de conjuntos de  $\Omega$ , y si  $P : \mathcal{M} \rightarrow [0, 1]$  es una función tal que:

- $P(\Omega) = 1$ .
- Si  $A_1, A_2, \dots, A_n \dots \in \mathcal{M}$   $A_i \cap A_j = \emptyset \forall i \neq j$ .

### Proposición 1.1.1 Propiedades de una probabilidad

1.  $P(\emptyset) = 0$ .

**Demostración:**  $\Omega = \Omega \uplus \emptyset \rightarrow P(\Omega) = P(\Omega \uplus \emptyset) = P(\Omega) + P(\emptyset)$ .

Por la propiedad 2, tenemos que  $P(\Omega) = 1$ , por lo que nos queda  $1 = 1 + P(\emptyset) \rightarrow P(\emptyset) = 0$ . ☺

2.  $P(A) \leq 1$  para cualquier evento  $A$ .

**Demostración:**  $\Omega = A \uplus A^c \rightarrow (1 =) P(\Omega) = P(A) + P(A^c)$ , como  $P(A^c) \geq 0$  por la primera propiedad, nos queda que  $P(A) \leq 1$ . ☺

3.  $P(A^c) = 1 - P(A)$ .

**Demostración:**

$$P(A \cup A^c) = P(A) + P(A^c) \quad (1.1)$$

$$\rightarrow P(\Omega) = 1 = P(A) + P(A^c) \quad (1.2)$$

$$\rightarrow P(A^c) = 1 - P(A) \quad (1.3)$$

☺

4. Si  $A \subseteq B \rightarrow P(A) \leq P(B)$ .

**Demostración:**

$$B = A \uplus (B \setminus A) \rightarrow P(B) = P(A) + P(B \setminus A) \quad (1.4)$$

$$\rightarrow P(A) \leq P(B) \quad (1.5)$$

☺

5.  $P(B \setminus A) = P(B) - P(A \cap B) \forall A, B$ .

**Demostración:**

$$B = (B \setminus A) \uplus (A \cap B) \rightarrow P(B) = P(B \setminus A) + P(A \cap B) \quad (1.6)$$

$$\rightarrow P(B \setminus A) = P(B) - P(A \cap B) \quad (1.7)$$

☺

6. Si  $A \subset B \rightarrow P(B \setminus A) = P(B) - P(A)$ .

**Demostración:** Como  $A$  esta incluido en  $B$ , tenemos que  $A \cap B = A$ . ☺

7.  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

**Demostración:**

$$P(A \cup B) = P((A \cap B) \cup (A/B) \cup (B/A)) \quad (1.8)$$

$$= P(A \cap B) + P(A/B) + P(B/A) \quad (1.9)$$

$$= P(A \cap B) + P(A) - P(A \cap B) + P(B) - P(A \cap B) \quad (1.10)$$

$$= P(A) + P(B) - P(A \cap B) \quad (1.11)$$

☺

$$8. P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C).$$

9. Sea  $\{C_n\}_n$  una sucesión de conjuntos tales que:

- $\cup_{i=1}^{\infty} C_i = \Omega$
- $C_i \cap C_j = \emptyset$  si  $i \neq j$

Entonces  $P(A) = \sum_{i=1}^{\infty} P(A \cap C_i) \forall A$ .

**Demostración:**  $A = \cup_{i=1}^{\infty} (A \cap C_i) \rightarrow P(A) = P(\cup_{i=1}^{\infty} (A \cap C_i)) = \sum_{i=1}^{\infty} P(A \cap C_i)$ . ☺

10. Continuidad de las probabilidades

- $A_1 \subset A_2 \subset \dots \subset A_n \subset \dots A_i \in \mathcal{M} \rightarrow P(\cup_{m=1}^{\infty} A_m) = \lim_{m \rightarrow \infty} P(A_m)$ .
- $A_1 \supset A_2 \supset \dots \supset A_n \supset \dots A_i \in \mathcal{M} \rightarrow P(\cap_{m=1}^{\infty} A_m) = \lim_{m \rightarrow \infty} P(A_m)$ .

#### Definición 1.1.7: Leyes de Morgan

- $(\cup_{n=1}^{\infty} A_n)^c = \cap_{n=1}^{\infty} A_n^c$ .
- $(\cap_{n=1}^{\infty} A_n)^c = \cup_{n=1}^{\infty} A_n^c$ .

## 1.2. Modelo de equiprobabilidad

Cuando  $\Omega$  es finito y además todos sus elementos tienen igual probabilidad, entonces  $A \subset \Omega$   $P(A) = \frac{|A|}{|\Omega|}$ .

## 1.3. Probabilidad Condicional

#### Definición 1.3.1

Sean  $A$  y  $B$  dos eventos de un espacio muestral  $\Omega$ , y supongamos que  $P(B) > 0$ . Definimos la probabilidad condicional de  $A$  dado  $B$  como

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$


Representa la probabilidad de  $A$  cuando se sabe que el evento  $B$  ha ocurrido

#### Proposición 1.3.1

- $P(A \cap B) = P(A|B)P(B)$  si  $P(B) \neq 0$ .
- $P(A \cap B) = P(B|A)P(A)$  si  $P(A) \neq 0$ .
- $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$  si  $P(A) \neq 0$  y  $P(B) \neq 0$ .
- Si  $\cup_{n=1}^{\infty} B_n = \Omega$   $B_i \cap B_j = \emptyset \forall i \neq j$   $P(B_n) \neq 0 \forall n$ .
  - $P(A) = \sum_{n=1}^{\infty} P(A|B_n)P(B_n)$ .
  - $P(B_k|A) = \frac{P(A|B_k)P(B_k)}{\sum_{n=1}^{\infty} P(A|B_n)P(B_n)}$ .
- $P(A|B) = 1 - P(A^c|B)$  si  $P(B) \neq 0$ .
- $P(A \cup B|C) = P(A|C) + P(B|C) - P(A \cap B|C)$  si  $P(C) \neq 0$ .

### Definición 1.3.2: Diagrama de árbol

Un árbol de probabilidad es una representación grafica de un conjunto de posibles resultados de un experimento aleatorio, donde cada nodo del árbol representa un evento y cada rama representa la probabilidad de que ocurra un resultado específico.



Para usar el árbol de probabilidad, podemos seguir una ruta específica desde el nodo raíz hasta un nodo terminal para determinar la probabilidad de que ocurra un resultado particular. Por ejemplo, para encontrar la probabilidad de que ocurra el evento  $B$ , podemos seguir la ruta de la izquierda desde el nodo raíz hasta el nodo terminal etiquetado con  $B$  y sumar las probabilidades a lo largo de esa ruta. En este caso la suma sería  $P(B) = P(A) * P(B|A) + P(A^c) * P(B|A^c)$ .

### Definición 1.3.3: Independencia de conjuntos

Sean  $A, B \in \mathcal{M}$  se dicen independientes si y solo si  $P(A \cap B) = P(A)P(B)$ .

#### Corolario 1.3.1

Si  $A$  y  $B$  son independientes, y  $P(B) \neq 0$ , entonces  $P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A)$ .

#### Corolario 1.3.2

$\emptyset$  y  $\Omega$  son independientes de  $A \forall A$ .

### Definición 1.3.4

$A, B, C$  son independientes si y solo si:

1. Los conjuntos son independientes 2 a 2.
2.  $P(A \cap B \cap C) = P(A)P(B)P(C)$ .

#### Proposición 1.3.2

Si  $A$  y  $B$  son independientes, entonces también lo son:

1.  $A$  y  $B^c$ .
2.  $A^c$  y  $B$ .
3.  $A^c$  y  $B^c$ .

## Capítulo 2

# Variables aleatorias

### Definición 2.0.1: Variables aleatorias

Una variable aleatoria es una función  $X : \Omega \rightarrow \mathbb{R}$  que a cada elemento del espacio muestral  $\omega$  asigna un número real  $X(\omega)$ .

La distribución de  $X$  queda determinada por los valores posibles que puede tomar y las probabilidades con que efectivamente lo hace.

### Definición 2.0.2: Variable aleatoria discreta

Una variable aleatoria  $X$  es discreta si su recorrido es numerable. Es decir, si podemos ordenar en una sucesión  $R_X = \{x_1, x_2, \dots\}$  los valores posibles que puede tomar. El recorrido de  $X$  puede ser tanto finito como infinito.

### Definición 2.0.3: Función de probabilidad puntual

Una función de probabilidad de una v.a. es la función  $P : \mathbb{R} \rightarrow [0, 1]$  definida por  $P_X(x) = P(X = x) \forall x \in \mathbb{R}$ . La distribución de  $X$  queda entonces determinada por su función de probabilidad puntual.

### Definición 2.0.4: Función de distribución de una v.a. $X$

Dada  $X$  v.a. en  $(\Omega, \mathcal{M}, P)$   $F_X : \mathbb{R} \rightarrow \mathbb{R}$  tal que  $F_X(x) = P(X \leq x)$ .

### Corolario 2.0.1 Propiedades

1.  $0 \leq F_X(x) \leq 1 \forall x \in \mathbb{R}$ .
2.  $F_X(x)$  es monótona creciente.
3.  $\lim_{x \rightarrow \infty} F_X(x) = 1$ .
4.  $\lim_{x \rightarrow -\infty} F_X(x) = 0$ .
5.  $F_X$  es continua por derecha ( $\lim_{x \rightarrow a^+} F_X(x) = F_X(a)$ ).

### Teorema 2.0.1

Si  $F : \mathbb{R} \rightarrow \mathbb{R}$  que cumple las propiedades anteriores entonces  $\exists (\Omega, \mathcal{M}, P)$  y  $\exists X$  variable aleatoria tal que  $F_X = F$ .

**Proposición 2.0.1**

Si defino  $F_X(a^-) = \lim_{x \rightarrow a^-} F_X(x)$  entonces:

1.  $P(a < X \leq b) = F_X(b) - F_X(a)$ .
2.  $P(a \leq X \leq b) = F_X(b) - F_X(a^-)$ .
3.  $P(a < X < b) = F_X(b^-) - F_X(a)$ .
4.  $P(a \leq X < b) = F_X(b^-) - F_X(a^-)$ .
5.  $P(X > a) = 1 - F_X(a)$ .
6.  $P(X \geq a) = 1 - F_X(a^-)$ .
7.  $P(X = a) = F_X(a) - F_X(a^-)$ .

**Lemma 2.0.1**

1. Conociendo la  $F_X$  puedo calcular la probabilidad de cualquier intervalo.
2. De (7) deduzco que conociendo  $F_X$  puedo obtener  $P_X$ .
3.  $P(X = a)$  = "salto de  $F_X$  en el punto  $a$ ".

**Definición 2.0.5: Clasificación de variables aleatorias**

Hay 3 tipos

1. Discretas: Una variable aleatoria  $X$  es discreta si y solo si  $\text{Rec}(X)$  es finito o infinito numerable.
2. Absolutamente continuas.
3. Mixtas.



### Definición 2.0.6: Modelos de Variables discretas

1. Variable Bernoulli:

Notación:  $X \sim \text{Ber}(p)$  con

$$X = \begin{cases} 1 & \text{caso de éxito} \\ 0 & \text{caso de fracaso} \end{cases}$$

$P = P(X = 1) = P(\text{éxito})$ , toda v.a. con  $\text{Rec}(X) = \{0, 1\}$  es Bernoulli donde éxito =  $\{X = 1\}$ .

2. Binomial  $X \sim \text{Bin}(m, p)$

Se repiten  $m$  veces pruebas independientes de Bernoulli con probabilidad  $p$  de éxito en cada prueba.

$X$  = cantidad de éxitos en las  $m$  pruebas.

$$\text{Rec}(X) = \{1, 2, \dots, n\}.$$

$$P(X = x) = C_x^m p^x (1 - p)^{m-x}.$$

3. Geométrica  $X \sim \text{Geo}(p)$

Se repiten pruebas independientes de Bernoulli con probabilidad  $p$  de éxito en cada prueba hasta que ocurra el primer éxito.

$X$  = cantidad de pruebas.

$$P(X = x) = p(1 - p)^{x-1}.$$

4. Binomial Negativa  $X \sim \text{BinNeg}(r, p)$

Igual a la geométrica pero se realiza hasta el  $r$ -ésimo éxito.

$X$  = cantidad de pruebas.

$$\text{Rec}(X) = \{r, r + 1, r + 2, \dots\}$$

$$P(X = x) = C_{x-1}^{r-1} p^r (1 - p)^{x-r}.$$

Si  $r = 1$  queda  $\text{Geo}(p)$ .

#### Ejemplo 2.0.1 (Bernoulli)

Tiro un dado  $X = \begin{cases} 1 & \text{si sale el 5} \\ 0 & \text{si no} \end{cases} \sim \text{Ber}(p = \frac{1}{6})$ , en este caso el éxito sería que salga el 5.

#### Ejemplo 2.0.2 (Binomial)

Tiro un dado 20 veces:

1. Hallar  $P(\text{exactamente 10 veces sale el 5})$ .

Defino  $X$  = cantidad de veces que sale el 5 en las 20 tiradas.

$P(X = 10) \rightarrow X \sim \text{Bin}(m = 20, p = \frac{1}{6})$  el éxito es que sale el 5 en una tirada, entonces

$$P(X = 10) = C_{10}^{20} \left(\frac{1}{6}\right)^{10} \left(\frac{5}{6}\right)^{10}$$

2. Hallar  $P(\text{al menos 2 veces sale un numero par})$ .

Defino  $X$  = cantidad de veces que sale un numero par en las 20 tiradas, es decir  $X \sim \text{Bin}(m = 20, p = \frac{1}{2})$  siendo el éxito que salga par en una tirada.

$$P(X \geq 2) = 1 - P(X < 2) = 1 - P(X = 0) - P(X = 1) = 1 - C_0^{20} \left(\frac{1}{2}\right)^{20} - C_1^{20} \frac{1}{2} \left(\frac{1}{2}\right)^{19}$$

**Ejemplo 2.0.3** (Geométrica)

Se sabe que las precipitaciones máximas mensuales en diciembre superan los  $200mm$  1 vez cada 100 años, calcular  $P(\text{haya que esperar al menos 5 años para que se vuelvan a superar los } 200mm)$

Definimos  $X = \text{cantidad de años hasta superar los } 200mm \text{ en diciembre} \sim Geo(p = \frac{1}{100})$ , entonces  $P(X \geq 5) = 1 - P(X = 1) - P(X = 2) - P(X = 3) - P(X = 4) - P(X = 5)$ , solo queda remplazar con la formula.

### Teorema 2.0.2 Primer Teorema de Continuidad

Sea  $A_1 \subseteq A_2 \subseteq A_3 \subseteq \dots$  ( $\{A_n\}_n$ ). Entonces:

- Existe  $\lim_{n \rightarrow \infty} P(A_n)$

Demostración: Como  $a_n = P(A_n)$  es una sucesión acotada en  $\mathbb{R}$  converge.

- Además:  $\lim_{n \rightarrow \infty} P(A_n) = P(A)$

Demostración: Como  $A_1 \cup A_2 \cup \dots \cup A_n = A_n$ , tenemos que  $\lim_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} A_n$ .

También  $\lim_{n \rightarrow \infty} P(A_n) = P(\lim_{n \rightarrow \infty} A_n)$  Con  $A_1 \cup A_2 = A_1 \uplus (A_2 \setminus A_1)$ ,  $A_1 \cup A_2 \cup A_3 = A_1 \uplus (A_2 \setminus A_1) \uplus (A_3 \setminus A_1)$

Sea  $\{B_n\}_n$  tal que  $B_n = A_n \setminus A_{n-1}$ , entonces  $\bigcup_{n=1}^{\infty} B_n = A$

**Definición 2.0.7**

Sea  $X : \Omega \rightarrow \mathbb{R}$ , definimos  $F_X : \mathbb{R} \rightarrow \mathbb{R}$  tal que  $F_X(z) = P(x \in z)$

**Proposición 2.0.2**

Propiedades de la  $fda$ :

1.  $0 \leq F_X(x) \leq 1 \quad \forall x$ .
2.  $F_X$  es creciente si  $x \leq y \rightarrow F_X(x) \leq F_X(y)$
3.  $\lim_{x \rightarrow \infty} F_X(x) = 1$
4.  $\lim_{x \rightarrow -\infty} F_X(x) = 0$
5.  $\lim_{x \rightarrow a^+} F_X(x) = F_X(a)$
6.  $P(x = a) = F_X(a) - \lim_{x \rightarrow a^-} F_X(x)$
7.  $P(x < a) = F_X(a) - P(x = a)$
8.  $P(a < X \leq b) = P(x \leq b) - P(X \leq a) = F_X(b) - F_X(a)$ , y  $(a < X \leq b) = \{x \leq b\} \setminus \{x \leq a\}$ .

**2.1. Variables aleatorias discretas con nombre****Definición 2.1.1: Variable aleatoria Bernoulli**

Diremos que  $X \sim \text{Ber}(p)$  ("X" distribuye como una Bernoulli de parámetro  $p$ ) con  $p \in [0, 1]$  si  $\text{Rec}(X) = \{0, 1\}$  y  $p_x(1) = p$  y  $p_x(0) = 1 - p$

Que modela? Modelamos experimentos en donde hay dos resultados posibles: Éxito (E) o Fracaso (F),

$$X(w) \begin{cases} 1 & \text{si } w \in E \\ 0 & \text{si } w \in F \end{cases}.$$

**Definición 2.1.2: Variable aleatoria binomial**

Diremos que  $X \sim \text{Bin}(n, p)$  (con  $n \in \mathbb{N}$  y  $p \in (0, 1)$ ) si  $\text{Rec}(X) = \{0, 1, 2, \dots, n\}$  y  $p_x(k) = C_k^n p^k (1-p)^{n-k} \geq 0$ .

Verificar  $\sum_{k \in \text{Rec}(X)} p_x(k) = 1$

$$\sum_{k=0}^n C_k^n p^k (1-p)^{n-k} = [p + (1-p)]^n = 1^n = 1$$

Que modelamos?

Hacemos  $m$  repeticiones del experimento tipo Bernoulli

$X = \#$  de Éxitos en esos  $m$  experimentos.

$P(X = k) = C_k^n p^k (1-p)^{n-k}$ , siendo  $C_k^n$  las # de formas de tener  $k$  éxitos ( $n - k$  F)

**Corolario 2.1.1**

Si  $X \sim \text{Bin}(n, p) \rightarrow X = X_1 + X_2 + \dots + X_n$  siendo  $X_i \sim \text{Bin}(p)$  independientes".

### Definición 2.1.3: Variable Aleatoria Geométrica

Diremos que  $X \sim \text{Geo}(p)$  con  $p \in (0, 1)$  si  $\text{Rec}(X) = \{1, 2, 3, \dots\} \in \mathbb{N}^+$  y  $p_x(k) = (1-p)^{k-1}p$   
 $\sum_{k=1}^{\infty} p_x(k) = \sum_{k=1}^{\infty} (1-p)^{k-1}p = p \sum_{k=0}^{\infty} (1-p)^k = p \frac{1}{1-(1-p)} = 1$

Que modela?

Se tienen repeticiones del tipo Bernoulli (con E o F) hasta que ocurre el primer Éxito  $X = \#$  de repeticiones del experimento.

$$P(X = k) = P(F, F, \dots, F, E) = (1-p)^k p$$

#### Ejemplo 2.1.1

Tirar la moneda HASTA que salga cara.

#### Corolario 2.1.2

Perdida de memoria: Sea  $X \sim \text{Geo}(p)$

$$P(X > m + n | X > n) = P(X > m)$$